F1nalyze

Klasyfikacja 4-klasowa wyników wyścigów Formuły 1

Mikołaj Koszewski

Wielowymiarowa Analiza Danych | 2026

Cel i dane

Zadanie predykcyjne

Dla każdego startu kierowcy w wyścigu przewidzieć jego klasę wynikową:

Klasa	Pozycja na mecie
wygrana	1
podium	2–3
punkty	4–10
reszta	>10

Metryka główna: macro-F1 (równe traktowanie wszystkich

Dane — F1nalyze Datathon

Zbiór	Lata	Obs.
train	1950–2013	21 966
validation	2013–2018	1 836
test	2018–2023	2 133

Podział czasowy (nie losowy)

Model musi generalizować w przód w czasie — symuluje realny przypadek użycia.

Krytyczny problem danych — zepsuty join

Surowe pliki to zepsuty iloczyn kartezjański: do każdego wyniku wyścigu doklejono ∼130–200 migawek klasyfikacji generalnej z różnych rund.

Plik	Wierszy surowych	Realne wpisy	Inflacja
train.csv	2 830 101	21 966	∼129×
validation.csv	353 762	1 836	∼193×
test.csv	352 928	2 133	∼165×

Symptom

Zmienna docelowa `position` przyjmuje ∼18 różnych wartości dla *tego samego* wpisu wynikowego — niemożliwa do nauczenia.

Naprawa

Zachować tylko wiersz, gdzie `raceId_y == racerId` → dokładnie **1 wiersz** na wynik (kierowca × wyścig).

Rozkład klas i wyzwania metodologiczne

Rozkład klas (train, po naprawie)

Klasa	N	%
wygrana	900	4,1%
podium	1 812	8,3%
punkty	6 321	28,8%
reszta	12 933	58,9%

Niezbalansowanie $\sim 14\times$ (reszta vs wygrana)

Główne wyzwania

- **Imbalance:** klasy mniejszościowe wymagają ważenia
- **Wyciek danych:** wiele kolumn to wyniki post-race (pozycja, punkty, czas — dostępne dopiero PO wyścigu)
- **Dryf czasowy:** ery F1 różnią się radykalnie (stawki, opony, aero)
- **Nowi kierowcy:** 64% `driverId` w test nie widzianych w train
- **DNF:** 48,5% wpisów to nieukończony wyścig — zaburza klasę „reszta"

Inżynieria cech — 17 zmiennych, zero wycieku

Kategoria	Cecha	Uzasadnienie
Pre-race	`grid`	Pozycja startowa — znana przed wyścigiem
	`year`, `round`	Czas / era F1
	`wiek_kierowcy`	Wiek w dniu wyścigu
Historia kierowcy (lagowane)	`punkty_przed`	Lag: punkty przed bieżącym wyścigiem
	`wygrane_przed`	Lag: wygrane kariery
	`forma_kierowcy`	Rolling-5 positionOrder, shift=1
	`doswiadczenie_kariery`	Cumcount startów per kierowca
Ryzyko DNF	`dnf_rate_kariera`	Historyczny % DNF per kierowca
	`dnf_forma_5`	Rolling-5 % DNF
Tor / konstruktor	`forma_zespolu`	Rolling-5 avg pozycji zespołu
	`chaos_circuit_hist`	Hist. zmienność wyników na torze
	`is_wet_prone`	Mokry tor (historycznie)
	`driver_circuit_form`	Rolling forma na konkretnym torze
	`freq_constructor/circuit`	Frequency encoding
Demograficzne	`nationality`	OrdinalEncoder

Modele i strategia walidacji

Modele (+ warianty z ważeniem klas)

Model	Opis
Reguła grid	*Baseline*: grid → klasa
Regresja logistyczna	Liniowy baseline ML
Las losowy (RF)	300 drzew, MDI
LightGBM	Gradient boosting, `max_depth=3`
LGB + kalibracja	Optymalizacja progów (Nelder-Mead)
Hierarchiczny	2-etapowy: top-10 vs reszta, potem

Walidacja krzyżowa

`TimeSeriesSplit(n_splits=5)`

Fold	Train	Val
1	1950–1967	1968–1977
2	1950–1978	1979–1987
3	1950–1987	1988–1994
4	1950–1994	1995–2004
5	1950–2004	2005–2013

Wybór hiperparametrów na `validation`, raport końcowy na `test`.

Wyniki — zbiorcza tabela modeli

Model	Val F1	Val BA	Test F1	Test BA
Reguła grid (baseline)	**0,600**	0,601	**0,553**	0,562
Regresja logistyczna	0,531	0,531	0,536	0,530
Las losowy (RF)	0,530	0,547	0,517	0,525
LightGBM	0,546	0,615	0,534	0,588
LGB + kalibracja progów	0,571	**0,643**	0,519	0,581
Model hierarchiczny	0,563	0,621	0,541	**0,591**

Kluczowy wniosek: baseline rządzi — macro-F1 = 0,60, bije wszystkie modele ML na macro-F1. LightGBM wygrywa w balanced accuracy (+4,2 pp na val) — lepiej radzi z klasami mniejszościowymi.

Analiza błędów — LightGBM per klasa

Recall i najczęstsze błędy (validation)

Klasa	N	Recall	Błąd →
wygrana	88	82%	podium
podium	178	35%	wygrana
punkty	621	66%	reszta
reszta	949	63%	punkty

Interpretacja

- **Podium** = najtrudniejsza klasa (recall 35%): granica podium/punkty jest najbardziej płynna sportowo
- **Wygrana** = model bardzo dobrze identyfikuje favorytów (82%)
- **Reszta** ↔ **punkty** = typowy błąd graniczący: kierowcy startujący z pozycji 8–12 są na granicy obu klas
- Cechy ryzyka DNF pomagają, ale nie rozwiązują problemu podium

Eksperyment: dryf czasowy — czy stare dane pomagają?

Dwa warianty treningu LightGBM

Train	Val F1	Test F1
Pełny (1950–2013)	0,546	0,534
Recency (2000–2013)	0,547	0,487

5 392 próbek (recency) vs 21 966 (pełny)

Wnioski

- Recency nieznacznie wygrywa na val (Δ+0,001)
- Recency przegrywa na test (Δ−0,047) — mniej danych, gorsza generalizacja
- Pełny train stabilniejszy pomimo dryfu między erami
- F1 lat 50-tych i 2020-ych to inny sport: inna stawka, punktacja, technologia

Przypadek ze zbioru testowego: Monaco GP 2021

Wyścig

Monaco Grand Prix 2021
Runda 5 · 20 kierowców

Model: Reguła grid (najlepszy na test, F1 = 0,553)

Predykcja na podstawie pozycji startowej — znana przed startem wyścigu.

Predykcja modelu — przed startem

Grid	Kierowca	Predykcja
P1	Leclerc	**wygrana**
P2	Verstappen	podium
P3	Bottas	podium
P4	Sainz	punkty
P5	Norris	punkty
P6	Gasly	punkty
P7	Hamilton	punkty
P8	Vettel	punkty
P9	Perez	punkty
P10	Giovinazzi	punkty
P11–P20	pozostali	reszta

Monaco GP 2021 — predykcja vs rzeczywistość

Grid	Kierowca	Predykcja	Wynik (klasa)	
P1	Leclerc	wygrana	reszta *(DNF — awaria)*	×
P2	Verstappen	podium	**wygrana**	≈
P3	Bottas	podium	reszta *(problem pit-stop)*	×
P4	Sainz	punkty	**podium**	≈
P5	Norris	punkty	**podium**	≈
P6	Gasly	punkty	punkty	✓
P7	Hamilton	punkty	punkty	✓
P8	Vettel	punkty	punkty	✓
P9	Perez	punkty	punkty	✓
P10	Giovinazzi	punkty	punkty	✓
P11	Ocon	reszta	punkty	≈
P12	Ricciardo	reszta	reszta	✓
P13	Stroll	reszta	punkty	≈
P14–P20 (pozostali)		reszta	reszta	✓

13/20 poprawnych (65%) × DNF z top-3 nieprzewidywalne

bez telemetrii ≈ klasa obok

Wnioski

Co zadziałało

- Diagnoza i naprawa zepsutego joina (warunek konieczny)
- 17 cech bez wycieku — lagowanie i rolling properly
- Kalibracja progów: **+0,025 F1** bez żadnego trenowania
- `TimeSeriesSplit`: walidacja zgodna z podziałem czasowym
- Model hierarchiczny: najlepszy balanced accuracy na test (0,591)

Co jest trudne strukturalnie

- `grid` dominuje — reguła trywialna bije ML na F1
- Klasa podium: recall 35% — największa trudność
- Dryf między erami F1 ogranicza transfer wiedzy
- 64% nowych kierowców w test — ID nie niesie informacji
- DNF (48%) to losowe zdarzenia — nieprzewidywalne bez telemetrii

Najlepszy model (macro-F1): **Reguła grid 0,553** na test. Najlepszy ML (balanced acc): **Model hierarchiczny 0,591**. Random classifier: ∼0,25.

Realne korzyści — gdzie to działa

Zastosowania praktyczne

- **Fantasy F1 / platformy bukmacherskie**
  Model daje probability per klasa — bezpośrednio jako wkład do odds
- **Analityka medialna / transmisje**
  Automatyczne prognozowanie wyników w trakcie kwalifikacji
- **Scouting historyczny**
  Kto był niedoceniany wg modelu? (wysoki pred. podium, słaby

Wartość metodologiczna

- **Naprawa zepsutego joina**
  Bezpośrednio zastosowalna do API F1 i podobnych relacyjnych zbiorów sportowych
- **Kalibracja progów bez retrenowania**
  Ogólna technika dla niezbalansowanych klas — działa z każdym modelem
- **Pipeline bez wycieku dla danych czasowych**
  Wzorzec lagowania i rolling dla

Dziękuję

Zbiór:	F1nalyze Datathon (1950–2023)
Modele:	LR, RF, LightGBM, Hierarchiczny
Najlepszy:	Reguła grid F1=0,553 / Hierarchiczny BA=0,591
Notebook:	`02_modelowanie_klasyfikacja.ipynb`