F1nalyze

Klasyfikacja 4-klasowa wyników wyścigów Formuły 1

Mikołaj Koszewski, Mateusz Gonera

Wielowymiarowa Analiza Danych · 2026

Cel i dane

Zadanie predykcyjne

Dla każdego startu kierowcy w wyścigu przewidzieć jego **klasę wynikową:**

Klasa	Pozycja na mecie
wygrana	`1`
podium	`2 – 3`
punkty	`4 – 10`
reszta	`> 10`

> Metryka główna: **macro-F1** — równe traktowanie wszystkich klas

Dane — F1nalyze Datathon

Zbiór	Lata	Obserwacje
`train`	1950 – 2013	21 966
`validation`	2013 – 2018	1 836
`test`	2018 – 2023	2 133

> **Podział czasowy — nie losowy**
> Model musi generalizować w przód w czasie — symuluje realny przypadek użycia. Nie ma wycieku przyszłości do treningowego.

Krytyczny problem danych — zepsuty join

Surowe pliki to **zepsuty iloczyn kartezjański** — do każdego wyniku wyścigu doklejono ~130–200 migawek klasyfikacji generalnej z różnych rund.

Plik	Wierszy surowych	Realne wpisy	Inflacja
`train.csv`	2 830 101	21 966	**~129×**
`validation.csv`	353 762	1 836	**~193×**
`test.csv`	352 928	2 133	**~165×**

Symptom

Zmienna ***position*** przyjmuje ~18 różnych wartości dla *tego samego* wpisu wynikowego — model nie ma szans się nauczyć.

Naprawa

Zachować tylko wiersz, gdzie ***raceId_y == raceId*** → dokładnie **1 wiersz** na wynik (kierowca × wyścig).

Rozkład klas i wyzwania metodologiczne

Rozkład klas (train, po naprawie)

Klasa	N	%
wygrana	900	4,1%
podium	1 812	8,3%
punkty	6 321	28,8%
reszta	12 933	58,9%

> Niezbalansowanie **~14×** (reszta vs wygrana)

Główne wyzwania

- **Imbalance** — klasy mniejszościowe wymagają ważenia
- **Wyciek danych** — wiele kolumn to wyniki post-race (pozycja, punkty, czas — dostępne dopiero po wyścigu)
- **Dryf czasowy** — ery F1 różnią się radykalnie (stawki, opony, aero)
- **Nowi kierowcy** — 64% driverId w teście nigdy nie widzianych w treningu
- **DNF** — 48,5% wpisów to nieukończony wyścig, zaburza klasę „reszta"

Inżynieria cech — 17 zmiennych, zero wycieku

PRE-RACE

- `grid` Pozycja startowa
- `year · round` Era F1
- `wiek_kierowcy` Wiek w dniu wyścigu

HISTORIA KIEROWCY (LAGOWANE)

- `punkty_przed` Lag: punkty przed wyścigiem
- `wygrane_przed` Lag: wygrane kariery
- `forma_kierowcy` Rolling-5 positionOrder (shift=1)
- `doswiadczenie_kariery` Cumcount startów

RYZYKO DNF

- `dnf_rate_kariera` Historyczny % DNF per kierowca
- `dnf_forma_5` Rolling-5 % DNF

TOR / KONSTRUKTOR

- `forma_zespolu` Rolling-5 avg pozycji zespołu
- `chaos_circuit_hist` Hist. zmienność wyników na torze
- `is_wet_prone` Mokry tor historycznie
- `driver_circuit_form` Rolling forma na tym torze
- `freq_constructor` Frequency encoding konstruktora
- `freq_circuit` Frequency encoding toru

DEMOGRAFICZNE

- `nationality` OrdinalEncoder

Zero wycieku: żadna cecha nie może być znana po starcie wyścigu.

Modele i strategia walidacji

Modele (+ warianty z ważeniem klas)

Model	Opis
Reguła grid	*Baseline: grid → klasa*
Regresja logistyczna	Liniowy baseline ML
Las losowy (RF)	300 drzew, MDI
LightGBM	Gradient boosting, max_depth=3
LGB + kalibracja	Optymalizacja progów (Nelder-Mead)

Walidacja krzyżowa czasowa

```
TimeSeriesSplit(n_splits=5)
```

Fold	Train	Val
1	1950–1967	1968–1977
2	1950–1978	1979–1987
3	1950–1987	1988–1994
4	1950–1994	1995–2004
5	1950–2004	2005–2013

Wybór hiperparametrów na validation, raport końcowy na test.

Wyniki — zbiorcza tabela modeli

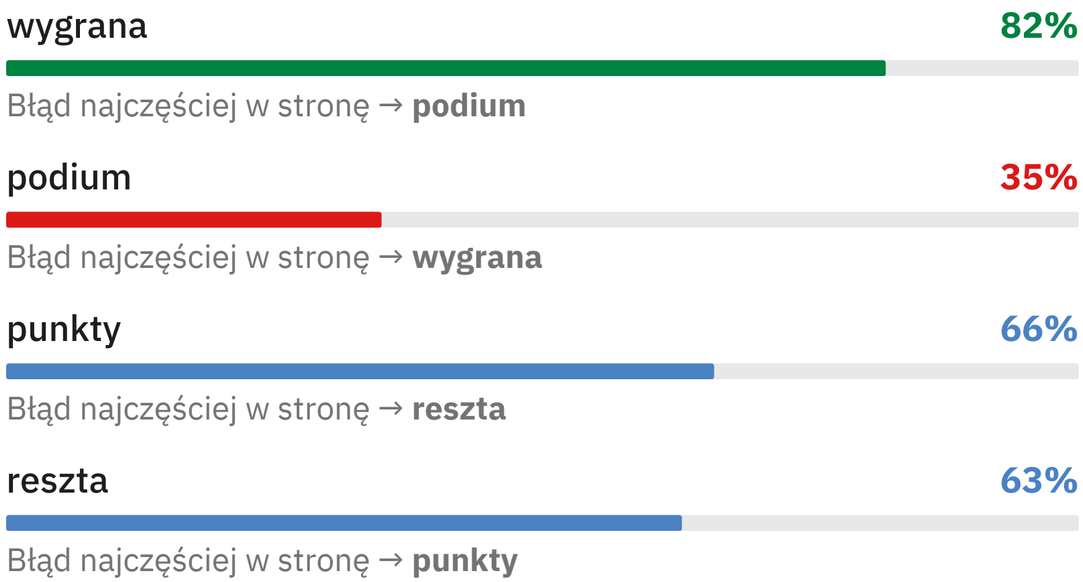
Model	Val F1	Val BA	Test F1	Test BA
Reguła grid (baseline)	**0,600**	0,601	**0,553**	0,562
Regresja logistyczna	0,531	0,531	0,536	0,530
Las losowy (RF)	0,530	0,547	0,517	0,525
LightGBM	0,546	0,615	0,534	**0,588**
LGB + kalibracja progów	0,571	**0,643**	0,519	0,581

Kluczowy wniosek: baseline rządzi na macro-F1 = **0,553** na test — bije wszystkie modele ML. Pozycja startowa jest zbyt silnym sygnałem.

LightGBM wygrywa na **Balanced Accuracy** (+4,2 pp na val) — lepiej radzi z klasami mniejszościowymi (wygrana, podium).

Analiza błędów — LightGBM per klasa

Recall per klasa (validation)



Interpretacja

- Podium = najtrudniejsza klasa (recall 35%)
- Granica podium/punkty jest najbardziej płynna sportowo — jeden pit-stop zmienia wynik
- Wygrana = model dobrze identyfikuje faworytów (82%)
- Kierowca z P1 i silną formą ma bardzo wysokie prawdop. wygranej
- Reszta ↔ punkty = typowe błędy graniczne
- Kierowcy startujący z P8–P12 są na granicy obu klas
- Cechy ryzyka DNF pomagają, ale nie rozwiązują problemu podium

Eksperyment: dryf czasowy — czy stare dane pomagają?

Dwa warianty treningu LightGBM

Zbiór train	Val F1	Test F1
Pełny (1950–2013)	0,546	**0,534**
Recency (2000–2013)	0,547	**0,487**

5 392 próbek (recency) vs 21 966 (pełny)

> Recency **przegrywa na test** o **−0,047** — mniej danych = gorsza generalizacja, mimo nowszych wzorców.

Wnioski

- Recency nieznacznie wygrywa na val (+0,001) ale **przegrywa na test**
- Pełny train jest **stabilniejszy** mimo dryfu między erami
- F1 lat 50-tych i F1 lat 2020-ych to **inny sport** — inna stawka, punktacja, technologia
- Dryf era-era jest realny, ale efekt **rozmiaru zbioru dominuje**
- Alternatywa: ważenie próbek w czasie (nowsze → wyższy weight) — nie testowane

Wnioski

Co zadziałało

- Diagnoza i naprawa zepsutego joina — warunek konieczny
- 17 cech bez wycieku — lagowanie i rolling properly
- Kalibracja progów: **+0,025 F1** bez żadnego trenowania
- TimeSeriesSplit — walidacja zgodna z podziałem czasowym

Co jest trudne strukturalnie

- **grid** dominuje — reguła trywialna bije ML na macro-F1
- Klasa **podium**: recall 35% — największa trudność
- Dryf między erami ogranicza transfer wiedzy
- 64% nowych kierowców w test — ID nie niesie informacji
- DNF (48%) to losowe zdarzenia — nieprzewidywalne bez telemetrii

Najlepszy model (macro-F1): **Reguła grid — 0,553 na test** · Najlepszy ML (balanced acc): **LightGBM — 0,588** · Random classifier: ~0,25

Realne korzyści — gdzie to działa

Zastosowania praktyczne

Fantasy F1 / platformy bukmacherskie

Model daje probability per klasa — bezpośrednio jako wkład do odds

Analityka medialna / transmisje

Automatyczne prognozowanie wyników w trakcie kwalifikacji

Scouting historyczny

Kto był niedoceniany? (wysoki pred. podium, słaby konstruktor)

Strategia pit-stop

Cechy ryzyka DNF informują o optymalnym momencie pit-stopu

Monaco GP 2021 — predykcja vs rzeczywistość

Grid	Kierowca	Predykcja	Wynik (klasa)	
P1	**Leclerc**	wygrana	*reszta* (DNF — awaria)	✗
P2	**Verstappen**	podium	**wygrana**	≈
P3	**Bottas**	podium	*reszta* (problem pit-stop)	✗
P4	**Sainz**	punkty	**podium**	≈
P5	**Norris**	punkty	**podium**	≈
P6	Gasly	punkty	punkty	✓
P7	Hamilton	punkty	punkty	✓
P8	Vettel	punkty	punkty	✓
P9	Perez	punkty	punkty	✓
P10	Giovinazzi	punkty	punkty	✓
P11	**Ocon**	reszta	**punkty**	≈
P12	Ricciardo	reszta	reszta	✓
P13	**Stroll**	reszta	**punkty**	≈
P14–P20	(pozostali)	reszta	reszta	✓

Legenda

- ✗ Błędna predykcja
- ≈ Klasa obok
- ✓ Poprawna predykcja

13/20
65% poprawnych

DNF z top-3 nieprzewidywalne bez telemetrii

Błędy graniczne: klasa obok, nie daleka chybka

Dziękujemy

Zbiór	F1nalyze Datathon (1950 – 2023)
Modele	LR, RF, LightGBM
Najlepszy F1	**Reguła grid – 0,553**
Najlepszy BA	**LightGBM – 0,588**